

Abgabe Blatt 9

Jean-Marco Alameddine, Johannes Kollek, Max Pernklau

Tuesday, January 17, 2017

Aufgabe 1

a)

Die Likelihoodfunktion ergibt sich zu

$$L = \prod_{n_i} \frac{\lambda^{n_i}}{n_i!} e^{-\lambda},$$

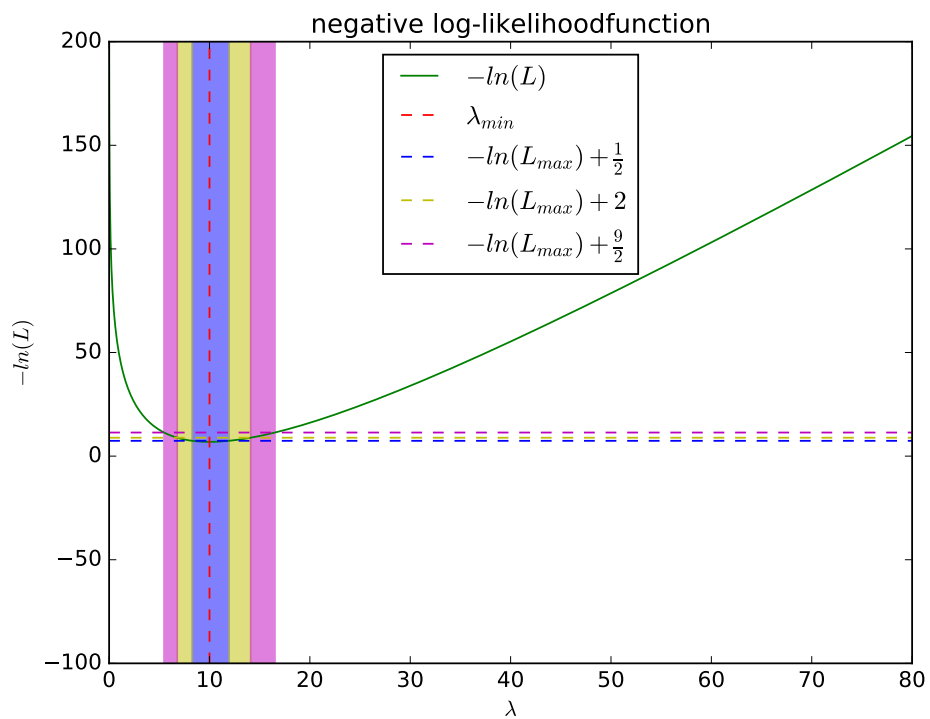
wobei

$$n_i = \{13, 8, 9\}$$

annehmen kann. Aus der Likelihoodfunktion folgt schließlich

$$\begin{aligned} -\ln(L) &= -\sum_{n_i} \ln \left(\frac{\lambda^{n_i}}{n_i!} e^{-\lambda} \right) \\ &= 3\lambda - \ln \left(\frac{\lambda^{13}}{13!} \right) - \ln \left(\frac{\lambda^8}{8!} \right) - \ln \left(\frac{\lambda^9}{9!} \right) \\ &= 3\lambda - 30 \ln(\lambda) + \ln(13! \cdot 9! \cdot 8!) \end{aligned}$$

für die negative Log-Likelihoodfunktion, welche in der nächsten Abbildung geplottet wird.



b)

Im Folgenden wird das Minimum der Funktion bestimmt.

$$\begin{aligned}\frac{\partial(-\ln(L))}{\partial\lambda} &= 3 - \frac{30}{\lambda} \stackrel{!}{=} 0 \\ &\Rightarrow \lambda_{min} = 10.\end{aligned}$$

c)

Aus der Bedingung

$$-\ln(\lambda_{min}) + a = -\ln(\lambda)$$

folgt mit $\lambda_{min} = 10$

$$3\lambda + 30(\ln(\lambda) - 1 - \ln(10)) - a = 0,$$

wobei

$$a = \left\{ \frac{1}{2}, 2, \frac{9}{2} \right\}$$

ist. Die Nullstelle wird numerisch über das Newton-Verfahren mit Kenntnis der Ableitung der negativen Log-Likelihoodfunktion bestimmt, wobei jeweils rechts und links von λ_{min} gestartet wird. Daraus ergeben sich die Grenzen der Intervalle

$$\begin{aligned}[8.284, 11.939] \text{ und } len &= 3.655, \text{ für } a = \frac{1}{2}; \\ [6.779, 14.109] \text{ und } len &= 7.33, \text{ für } a = 2; \\ [5.474, 16.52] \text{ und } len &= 11.046, \text{ für } a = \frac{9}{2}.\end{aligned}$$

Diese Intervalle sind ebenfalls im Plot eingezeichnet. Diese Intervalle können Konfidenzintervalle bzgl. der Schätzung des Erwartungswertes λ darstellen. Liegt das tatsächliche λ außerhalb dieses gewählten Bereiches kann die Schätzung verworfen werden.

d)

Das zweite Taylorpolynom ergibt sich zu

$$T_2(10, -\ln(L)) = 10 - 30 \ln(10) + \frac{3}{20}(\lambda - 10)^2 + \ln(13! \cdot 9! \cdot 8!).$$

Diese Funktion ist in der nächsten Abbildung zu sehen.

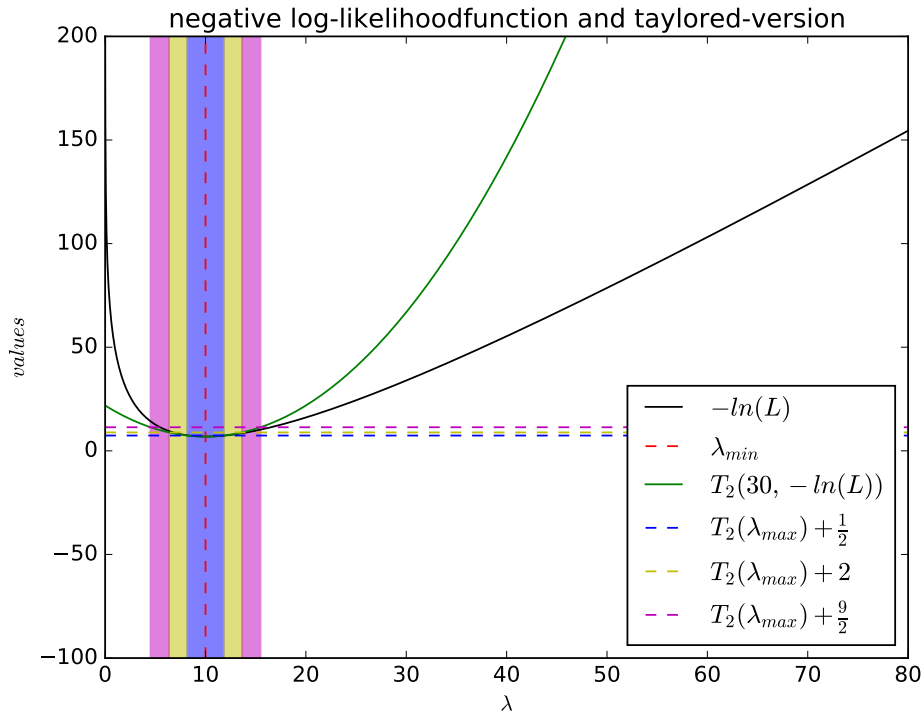


Figure 1: Negative Log-Likelihoodfunktion und Taylorpolynom.

Die λ werden auch hier numerisch bestimmt, wobei diese hier auch analytisch gewonnen werden können. Die Intervalle lauten

$$\begin{aligned}
& [8.174, 11.826] \text{ und } len = 3.651, \text{ für } a = \frac{1}{2}; \\
& [6.349, 13.651] \text{ und } len = 7.303, \text{ für } a = 2; \\
& [4.523, 15.477] \text{ und } len = 10.954, \text{ für } a = \frac{9}{2}.
\end{aligned}$$

Die relativen Abweichungen zum exakten Ergebnis lauten

$$\begin{aligned}
& 0.093 \%, \text{ für } a = \frac{1}{2}; \\
& 0.369 \%, \text{ für } a = 2; \\
& 0.828 \%, \text{ für } a = \frac{9}{2}.
\end{aligned}$$

Diese Abweichungen sind sehr gering und somit ist das Taylorpolynom eine gute Näherung an die analytisch kompliziertere negative Log-Likelihoodfunktion. Der Vorteil am Polynom ist, dass damit viel besser gerechnet werden kann.

Aufgabe 2

Die Aufgabe wurde handschriftlich bearbeitet. Wo Rechenschritte fehlen, beispielsweise beim Berechnen vom Lösungsvektor, wird die Rechnung im Code in der Datei *aufg2.py* durchgeführt. Diese enthält als Ausgabe ebenfalls die in der Aufgabenstellung gefragten Werte.

Nr. 2

$$\begin{aligned} a) \quad f(\psi) &= a_1 p_1(\psi) + a_2 p_2(\psi) \\ &= a_1 \cos(\psi) + a_2 \sin(\psi) \end{aligned}$$

$$A = \begin{pmatrix} p_1(\psi_1) & p_2(\psi_1) \\ \vdots & \vdots \\ p_n(\psi_n) & p_n(\psi_n) \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ \sqrt{3}/2 & 1/2 \\ 1/2 & \sqrt{3}/2 \\ 0 & 1 \\ -1/2 & \sqrt{3}/2 \\ -\sqrt{3}/2 & 1/2 \\ -1 & 0 \\ -\sqrt{3}/2 & -1/2 \\ -1/2 & -\sqrt{3}/2 \\ 0 & -1 \\ \sqrt{3}/2 & -1/2 \\ 1/2 & -\sqrt{3}/2 \end{pmatrix} \begin{matrix} 0^\circ \\ 30^\circ \\ 60^\circ \\ 90^\circ \\ 120^\circ \\ 150^\circ \\ 180^\circ \\ 210^\circ \\ 240^\circ \\ 270^\circ \\ 300^\circ \\ 330^\circ \end{matrix}$$

b) Lösungsvektor: $\vec{a} = (A^T A)^{-1} A^T \vec{y}$

$$A^T A = \begin{pmatrix} 6 & 0 \\ 0 & 6 \end{pmatrix} \leadsto (A^T A)^{-1} = \begin{pmatrix} 1/6 & 0 \\ 0 & 1/6 \end{pmatrix}$$

$$\text{mit } \vec{y} = \begin{pmatrix} -0.032 \\ 0.010 \\ 0.057 \\ \vdots \end{pmatrix}$$

$$\Rightarrow \vec{a} = \begin{pmatrix} -0.0375063 \\ 0.07739978 \end{pmatrix} = \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$$

c) Asymptotische Werte sind (vermutlich) unkorreliert mit $\Sigma = 0.011$

$$\begin{aligned} \Rightarrow V[\vec{a}] &= \Sigma^2 (A^T A)^{-1} \\ &= (0.011)^2 \cdot \begin{pmatrix} 1/6 & 0 \\ 0 & 1/6 \end{pmatrix} = \begin{pmatrix} 2.0167 \cdot 10^{-5} & 0 \\ 0 & 2.0167 \cdot 10^{-5} \end{pmatrix} \\ &= V[\vec{a}] \end{aligned}$$

\Rightarrow Fehler von a_1/a_2 ist $\sqrt{2.0167 \cdot 10^{-5}} = 0.0044907$
Korrelationskoeffizient ist 0, da die Nebendiagonalelemente der Kovarianzmatrix verschwinden

$$d) f(\varphi) = a_1 \cos(\varphi) + a_2 \sin(\varphi)$$

$$A_0 \cdot \cos(\varphi + \delta) = A_0 \cdot \cos(\varphi) \cos(\delta) - A_0 \sin(\varphi) \sin(\delta)$$

$$\Rightarrow A_0 \cos(\delta) = a_1 \quad \wedge \quad -A_0 \sin(\delta) = a_2 \quad (II)$$

$$\text{div. II: } -\tan(\delta) = \frac{a_2}{a_1} \Rightarrow \underline{\underline{\delta = \arctan(-\frac{a_2}{a_1})}}$$

$$\text{und: aus I: } A_0 \cos(\arctan(-\frac{a_2}{a_1})) = a_1$$

$$\Leftrightarrow A_0 \cdot \frac{1}{\sqrt{a_1^2/a_1^2 + 1}} = a_1$$

$$\Rightarrow \underline{\underline{A_0 = a_1 \sqrt{a_2^2/a_1^2 + 1}}}$$

$$\Rightarrow \boxed{\begin{matrix} A_0 = -0.086008 \\ \delta = 1.1195615 \end{matrix}}$$

$$\text{Transformation? } V[A_0, \delta] = J \cdot V[a_1, a_2] J^T \quad \text{mit } V[a_1, a_2] = \begin{pmatrix} 2.0167 \cdot 10^{-5} & 0 \\ 0 & 2.0167 \cdot 10^{-5} \end{pmatrix}$$

$$J = \begin{pmatrix} \frac{\partial A_0}{\partial a_1} & \frac{\partial A_0}{\partial a_2} \\ \frac{\partial \delta}{\partial a_1} & \frac{\partial \delta}{\partial a_2} \end{pmatrix}$$

$$\frac{\partial A_0}{\partial a_1} \neq \frac{a_1}{a_1^2 + 1} = \left(\frac{a_2^2}{a_1^2} + 1\right)^{-1/2} \approx 0.436077$$

$$\frac{\partial A_0}{\partial a_2} \neq \frac{a_2}{a_1} \left(\frac{a_2^2}{a_1^2} + 1\right)^{-1/2} \approx -0.89991$$

$$\frac{\partial \delta}{\partial a_1} = \frac{a_2}{a_1^2 + a_2^2} \approx 10.46304$$

$$\frac{\partial \delta}{\partial a_2} = \frac{-a_1}{a_1^2 + a_2^2} \approx 5.07017$$

$$\Rightarrow V[A_0, \delta] = \begin{pmatrix} 2.016 \cdot 10^{-5} & -1.17707 \cdot 10^{-10} \\ -1.17707 \cdot 10^{-5} & 2.72528 \cdot 10^{-3} \end{pmatrix}$$

$$\Rightarrow \sigma_{A_0} \approx 0.00449$$

$$\sigma_{\delta} \approx 0.0522$$

$$\sigma_{A_0 \delta} = \frac{\sigma_{A_0} \sigma_{\delta}}{\sigma_{A_0} \sigma_{\delta}} = \frac{-1.17707 \cdot 10^{-10}}{\sigma_{A_0} \sigma_{\delta}} \approx -0.00205 \quad \text{als Korrelationskoeffizient}$$

Zudem führt *auf2_test.py* den zuvor berechneten Fit durch, um zu Zeigen dass die Methode erfolgreich war.




Figure 2: Aufgabe 2- Fit.

Aufgabe 3

a)

Zunächst werden die Daten mit der Methode der kleinsten Quadrate gefittet. Der Lösungsvektor ergibt sich aus

$$\hat{a} = (A^T A)^{-1} A^T \vec{y} \quad (1)$$

Die Koeffizienten lauten

$$a_0 = -6.744\,532\,69 \times 10^{-2} \quad (2)$$

$$a_1 = 6.096\,090\,41 \times 10^{-1} \quad (3)$$

$$a_2 = -5.137\,482\,17 \times 10^{-1} \quad (4)$$

$$a_3 = 2.105\,665\,23 \times 10^{-1} \quad (5)$$

$$a_4 = -4.520\,077\,56 \times 10^{-2} \quad (6)$$

$$a_5 = 4.785\,680\,54 \times 10^{-3} \quad (7)$$

$$a_6 = -1.962\,881\,98 \times 10^{-4} \quad (8)$$

(*Anmerkung des Autorenteam:* Die Koeffizienten und alle folgenden Werte werden auch von der Konsole beim Ausführen von *aufg3.py* ausgegeben. Im Zweifel sind die dort ausgegebenen Werte die richtigen, da Kopierfehler immer passieren können...)

b)

Als nächstes wird eine Regularisierung genutzt. Dabei wird der Parameter λ variiert.

Der Schätzparameter ergibt sich zu

$$\hat{a}^{reg} = (A^\top A + \lambda(CA)^\top(CA))^{-1} A^\top \vec{y} \quad (9)$$

wobei C Teil einer Regularisierung mithilfe der zweiten numerischen Ableitung ist (siehe Skript, Seite 92, Kapitel Testen.)

(*Anmerkung des Autorenteam:* Uns ist nicht klar, wieso C so aussehen muss, um eine zweite Ableitung zu repräsentieren, bzw. ob C hier richtig angewendet wird. Eine Aufklärung in der Übungs wäre vorteilhaft!)

Die Koeffizienten für alle Lambdas werden durch die Konsole ausgegeben, als Beispiel seien die Koeffizienten für $\lambda = 0.1$ angegeben:




Figure 3: Aufgabe 3a - Fit.

$$a_0 = 5.279\,658\,56 \times 10^{-2} \quad (10)$$

$$a_1 = 2.595\,311\,49 \times 10^{-1} \quad (11)$$

$$a_2 = -1.932\,312\,85 \times 10^{-1} \quad (12)$$

$$a_3 = 7.696\,672\,46 \times 10^{-2} \quad (13)$$

$$a_4 = -1.716\,280\,69 \times 10^{-2} \quad (14)$$

$$a_5 = 1.903\,764\,83 \times 10^{-3} \quad (15)$$

$$a_6 = -8.103\,496\,97 \times 10^{-5} \quad (16)$$




Figure 4: Aufgabe 3b - Fit.

c)

Zuletzt soll an einer größeren Datenmenge die gewichtete Methode zum Fitten genutzt werden.

Gefittet wird dabei jeweils an den Mittelwert der Messdaten zu jedem x , das Quadrat der Inverse vom Fehler des Mittelwertes wird dabei jeweils als Wichtungparameter verwendet. (Ist das Quadrat hier richtig/nötig?)

Als Schätzer ergibt sich nun

$$\hat{a} = (A^T W A)^{-1} A^T W \vec{y} \quad (17)$$

wobei die Gewichtsmatrix W jeweils als Diagonalelemente die bereits angesprochenen Gewichte enthält.

Als Gewichte ergeben sich dabei:

$$a_0 = -1.114\,069\,47 \times 10^{-1} \quad (18)$$

$$a_1 = 7.632\,110\,82 \times 10^{-1} \quad (19)$$

$$a_2 = -6.800\,067\,87 \times 10^{-1} \quad (20)$$

$$a_3 = 2.893\,991\,63 \times 10^{-1} \quad (21)$$

$$a_4 = -6.339\,377\,99 \times 10^{-2} \quad (22)$$

$$a_5 = 6.792\,775\,85 \times 10^{-3} \quad (23)$$

$$a_6 = -2.810\,139\,23 \times 10^{-4} \quad (24)$$




Figure 5: Aufgabe 3c - Fit.